모델링 결과서

접수번호	A371717
팀명	보들이의 여정
공모전 중복 참여여부	2025 KCB Global AI Hackathon (Kensington College Brunei, 서비스 부문 Achievement Award) 2026 한국디지털산업학회 대학(원)생 아이디어 공모전 (한국디지털산업학회, 최우수상(2nd Prize)) 2026 영천시 공공데이터・AI 활용 창업 경진대회 (영천시, 최우수상(1st Prize)) 2026 캠퍼스 특허유니버시아드 (장려상,AI 프로그램을 활용해 특허 분석) 2026 제 6 회 K-인공지능 KAMP 제조데이터 분석 경진대회 (진행중)
주요 활용 라이브러리	Python 3.11, PyTorch(CUDA), segmentation-models-pytorch, NumPy, SciPy, scikit-image, Pillow, pandas, Matplotlib

배경 및 아이디어 소개(요약)

◦ **아이디어 제안 배경**

고탄성 Al-Si-Ni 주조합금의 탄성률은 Al 기지(70 GPa)보다 단단한 Si(160 GPa)와 Al_3Ni(143 GPa)의 분율에 좌우되므로 상 분할이 중요하다. 다만 공정 Si는 2~5 픽셀로 가늘고 밝기가 겹쳐 밝기 기준 분할은 mIoU 48.1%에 그쳤고, 사진마다 해상도가 달랐다. 조직 크기 기준 정규화를 핵심으로, 고성능 배율의 공정 Si 두께가 약 8 픽셀에 모이고 10 픽셀 이상에서 성능이 저하됨을 확인하였다. AI가 두께로 배율을 정하는 정규화 모델 3 개를 더해 10 개 앙상블을 구성하였다.

◦ **파급효과**

최종 모델은 검증 mIoU 80.93%(밝기 기준 +32.8%p)를 기록하였으며, 촬영 배율 정보 없이 조직 두께로 배율을 정해 다른 촬영 환경으로 확장하기에 유리하다. AI・정답 마스크의 탄성률 추정값 차이는 평균 1.05 GPa로 동일 step 내 사진 간 변동(4.93 GPa)보다 작았고, 현재 구성비 가정에서 100 GPa에는 경질상 약 46%가 필요한 것으로 계산되었다. 잔여 오차는 경계 민감도와 얇은 상 판별 한계로 분석해 시편 준비 지침으로 연결하였다.

고탄성 알루미늄 합금 이미지 상 분할 인공지능 모델

분석・모델링 결과서(10 페이지 이내)

① 분석(EDA) 개요

1-1. 분석 핵심 내용

1) 데이터 구성

◦ train 70 장과 valid 20 장은 광학현미경(OM) 흑백 사진과 4 상 정답 마스크로, test 10 장은 사진으로만 구성됨

- 사진 크기는 675×480 부터 1440×1024 까지 5 종이며, 정답 마스크에서 상이 지정되지 않은 픽셀은 없었음

2) 공정 Si의 두께 진단

◦ 가장 중요한 발견은 공정 Si가 4 픽셀 안팎의 매우 가는 구조라는 점임

- 정답 마스크 90 장에서 공정 Si의 뼈대를 추출하고, 뼈대 위치마다 경계까지의 거리를 재어 국부 두께를 구한 결과 중앙값은 4 픽셀, 71.4%가 4 픽셀 이하였음 (<그림 1-2>)
- 분할 모델의 인코더는 첫 단계에서 사진을 1/4 로 줄이므로, 4 픽셀 두께의 공정 Si는 1 픽셀 이하로 줄어 형태 정보가 거의 남지 않음

3) 상별 밝기 분포의 중첩

◦ 상별 평균 밝기는 초정 Si 61, 공정 Si 100, Al_3Ni 142, Al 212 순이나 분포가 넓게 겹침 (<그림 1-1>(c))

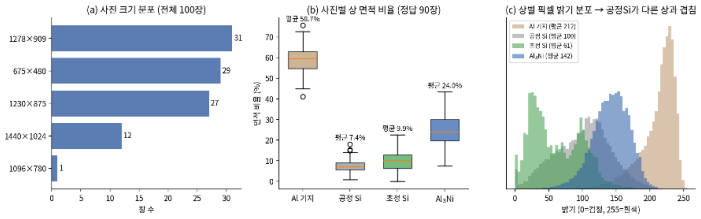
- 공정 Si는 가늘고 경계 픽셀 비중이 높아 주변 Al의 영향을 받기 쉬우며 중간 밝기 영역에 넓게 분포함. 같은 초정 Si도 사진별 밝기가 달라짐

◦ train 데이터로 경계를 정한 밝기 임계값 방식은 mIoU 48.1%, 공정 Si IoU 17.4%에 그쳐, 밝기만으로는 상을 구분하기 어려운 것으로 판단함

4) 클래스 불균형과 촬영 조건 편차

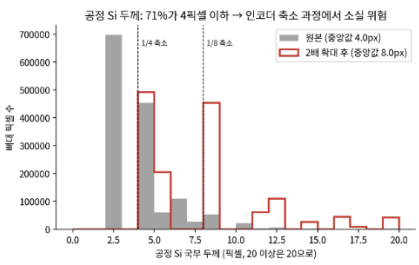
◦ 면적 비율은 Al 58.7%, Al_3Ni 24.0%, 초정 Si 9.9%, 공정 Si 7.4%로 불균형하며, 초정 Si가 없는 사진도 2 장 있었음 (<그림 1-1>(b))

◦ 사진별 평균 밝기는 139~200 으로 편차가 커, 2-1 에서 밝기 · 대비 증강을 적용하는 근거로 사용함



<그림 1-1> 사진 크기, 상 면적 비율, 상별 밝기 분포

* (a) 사진 크기 5 종 (b) 사진별 상 면적 비율 (c) 상별 픽셀 밝기 분포로, 공정 Si(회색)가 초정 Si·Al_3Ni와 넓게 겹침



<그림 1-2> 공정 Si 국부 두께 분포

* 회색은 원본, 빨간 선은 2 배 확대 후의 분포이며, 점선은 인코더의 1/4·1/8 축소 단계에 해당하는 두께임

1-2. 분석 배경

1) 응고 순서로 본 분할 난이도

◦ 과공정 Al-Si-Ni 합금은 응고할 때 초정 Si가 가장 먼저 정출되고, 이어서 Al 수지상이 성장하며, 마지막으로 남은 액상이 Al · Si · Al_3Ni 3 원 공정으로 굳음

- 초정 Si는 크고 각진 독립 입자여서 형상만으로도 구분이 쉬움
- 반면 공정 Si와 Al_3Ni는 같은 공정 영역 안에서 얽혀 자라므로, 경계를 판단하려면 한 점의 밝기보다 넓은 주변 형태를 함께 보아야 함

2) 상 분율과 탄성률의 관계

◦ Delesse 원리에 따라 대표 단면의 면적 분율을 부피 분율 추정에 활용할 수 있어, 분할 상 분율을 복합재 탄성 모델 입력으로 사용함

- Al 기지(약 70 GPa)보다 Si(약 160 GPa)와 Al_3Ni(약 143 GPa)가 훨씬 단단하므로, 경질상 분율이 합금 탄성률을 좌우함

1-3. 분석 방법 및 분석 내용

◦ 이미지는 해상도 · 밝기 · 상별 밝기 분포를, 마스크는 상 면적 분율 · 공정 Si 국부 두께 · 초정 Si 최소 면적 분율(1.53%, 2-1 후처리 기준)을, 파일명은 step 번호를 분석에 활용함

1) step별 조직 비교

◦ step별 경질상 총량은 40.2~42.2%로 거의 일정하였으나, step이 커질수록 공정 Si는 9.0%에서 6.4%로 줄고 Al_3Ni는 21.2%에서 26.9%로 늘었음 (정답 마스크 90 장 기준)

- step이 증가할수록 경질상 총량은 유사하나 공정 Si는 감소하고 Al_3Ni는 증가해, 본 데이터에서는 step 차이가 총량보다 두 상의 분율 변화와 더 크게 연관됨
- 탄성률로 환산하면 step 사이의 차이보다 같은 step 안의 사진 간 차이가 더 컸으며, 이는 ④에서 다시 확인함

② 데이터 전처리

2-1. 전처리 방법

1) 입력 2 배 확대

◦ 1-1 의 두께 진단에 따라 사진은 bicubic, 정답 마스크는 nearest 방식으로 2 배 확대하여 공정 Si 두께 중앙값을 8 픽셀로 확보함

- 예측 후에는 확률 지도를 면적 평균 방식으로 원래 크기로 줄여 제출 마스크 크기를 원본과 맞춤

◦ 동일 모델에서 2 배 확대 전 · 후를 비교한 결과, 검증 mIoU가 77.8%에서 79.03%로 올랐으며 공정 Si가 2.4%p로 가장 크게 개선됨

2) 데이터 증강

◦ 조직에는 방향이 없으므로 90° 회전 · 좌우 반전을, 사진별 밝기 편차(139~200)를 반영해 대비 0.8~1.2 배 · 밝기 ±0.1 · 감마 0.8~1.25 를 무작위로 적용함

◦ 증강 여부만 달리한 비교에서 검증 mIoU는 74.7%에서 77.2%로 올랐음

◦ 증강은 train 70 장에서만 학습 중 실시간으로 생성하였으며(에폭당 1,000 조각, 모델당 10 만~15 만 조각), 외부 데이터와 검증 · 테스트 사진은 학습에 사용하지 않음

3) 후처리: 초정 Si 부재 판정

◦ 초정 Si가 있는 사진은 최소 1.53%의 면적을 가지므로, 예측된 초정 Si 면적이 0.5% 미만이면 오검출로 보고 해당 픽셀을 두 번째로 확률이 높은 상으로 바꿈

- 기준값은 train 정답 마스크의 통계로만 정함

4) 조직 크기 기반 추론 배율

◦ 같은 2 배 확대라도 사진마다 공정 Si의 화소 두께가 달라(검증 사진 기준 가로 675 사진 2.3~3.2 픽셀, 1278 사진 2.8~6.1 픽셀), 모델이 보는 조직 크기가 사진마다 다름

◦ 검증 20 장을 2・3・4 배로 각각 예측해 비교한 결과, 사진별로 점수가 가장 높은 배율에서의 확대 후 두께는 중앙값 8.2 픽셀(사분위 6.6~9.5 픽셀)이었음 (<그림 2-1>(a))

- 이는 train 정답으로 미리 구한 목표 두께 8.0 픽셀(큰 사진의 평균 두께 × 2)과 근접함
- 본 검증에서는 확대 후 10 픽셀 이상부터 점수가 낮아져(10~12 픽셀 -3.4%p, 16 픽셀 이상 -14.6%p), 과도한 확대가 불리한 경향을 보임
- 따라서 본 데이터에서는 사진 크기보다 조직의 화소 크기를 기준으로 배율을 정하는 것이 적절함

◦ 적용: 가로 800 픽셀 미만 사진은 2・3・4 배 예측을 평균하여 전체 mIoU가 80.39%에서 80.73%로 오름 (작은 사진 9 장 평균 78.30% → 79.06%)

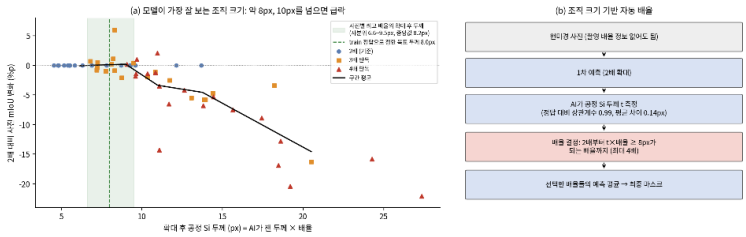
- 큰 사진까지 2・3 배를 섞으면 80.14%, 모든 사진을 2・3・4 배로 하면 78.80%로 낮아져 위 결과와 같은 경향을 보임

◦ 일반화: AI가 1 차 예측에서 공정 Si 두께를 직접 재고, 2 배부터 두께×배율이 목표 이상이 되는 배율까지 평균하는 자동 배율을 설계함 (<그림 2-1>(b))

- AI가 잰 두께는 정답으로 잰 두께와 상관계수 0.99, 평균 차이 0.14 픽셀로 정확하였음
- 자동 배율 80.67%는 사진 크기 규칙(80.73%)과 유사하며, 촬영 배율 정보를 쓰지 않아 다른 촬영 환경으로 확장하기에 유리하나 외부 데이터 검증이 필요

◦ 학습 확장(조직 크기 정규화 학습): train 정답으로 잰 두께로 사진마다 배율(1.5~4 배)을 정해 공정 Si가 약 8 픽셀로 보이도록 확대 학습한 모델 3 개를 추가하고, 예측은 위 자동 배율로 함

- 단독 앙상블은 80.21%로 기존 7 개보다 낮으나, 같은 조직을 다른 크기로 학습해 틀리는 위치가 달라 기존 7 개와 결합하면 80.93%로 오름
- 같은 수의 모델을 더한 다른 실험(학습 조각 960 80.37~80.44%, 상별 밝기 증강 80.27%)에서는 같은 개선이 없어, 조직 크기가 다른 모델의 다양성이 기여했을 가능성이 있음
- 가장 떨어진 A42(84.4% → 83.8%)는 두께 6.8 픽셀의 두꺼운 사진으로, 배율 하한(1.5 배) 때문에 확대 후 두께가 10 픽셀을 넘어 (a)의 급락 구간과 일치함
- 배율 하한을 1.0 으로 낮춘 추가 학습에서는 A42 가 단독 85.0%로 회복되어 이 해석을 뒷받침하였으나, 앙상블 전체는 80.97%(+0.04%p)로 기준에 미달하여 채택하지 않음



<그림 2-1> 확대 후 조직 두께에 따른 성능 변화와 자동 배율 절차

* (a) 검증 20 장의 3 배·4 배 단독 예측을 2 배와 비교한 결과이며, 초록 띠는 사진별 최고 배율에서의 두께 범위임 (b) 정답 정보는 사용하지 않음

2-2. 전처리 절차

◦ 기본 7 개 모델은 2 배 확대, 정규화 3 개 모델은 두께에 따라 1.5~4 배 확대해 공정 Si가 약 8 픽셀이 되도록 학습함

- 학습: 위 배율 적용 후 512 또는 768 크기 조각을 무작위로 잘라 에폭마다 1,000 개를 사용하고 증강을 적용함
- 추론: 1,024 크기 조각을 128 픽셀씩 겹쳐 예측하고 겹친 부분은 평균하며, 회전 4 종과 반전 2 종을 조합한 8 방향 결과를 다시 평균함(TTA), 작은 사진은 2 · 3 · 4 배 결과를, 조직 크기 정규화 모델은 측정 두께 기준 배율 결과를 사용함

③ 모델링

3-1. 배경/알고리즘 소개

1) U-Net 구조

◦ U-Net은 사진을 단계적으로 줄이며 넓은 범위의 특징을 읽는 인코더와, 다시 키우며 픽셀 단위로 상을 칠하는 디코더로 이루어짐 [1]

2) 인코더 선택

◦ ImageNet으로 사전학습한 ResNet34 를 인코더로 사용하였으며, 더 큰 인코더(ResNeXt50, MiT-B2)는 학습 사진 70 장 규모에서 오히려 낮았음 (<표 3-1>)

- 현미경 사진으로 사전학습한 MicroNet 가중치 [2]도 ImageNet 가중치와 차이가 없어 ImageNet 가중치를 유지함

3) scSE 주의 모듈

◦ 디코더 각 단계에 scSE 모듈을 넣어, 어떤 특징이 중요한지(채널)와 사진의 어느 위치가 중요한지(공간)를 함께 가중함 [3]

4) 손실함수

◦ 픽셀별 분류 오차인 Cross-Entropy에, IoU를 직접 높이도록 설계된 Lovász-Softmax 손실을 더함 [4]

3-2. 모델링 방법

1) 학습 설정

◦ AdamW(학습률 3×10^{-4}), cosine 방식 학습률 감소, 100~150 에폭, 혼합정밀도(AMP)로 학습함

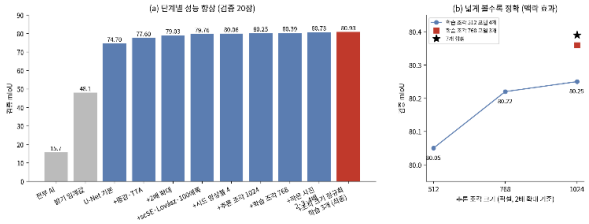
◦ 5 에폭마다 검증 mIoU를 계산하여 가장 높았던 시점의 가중치를 저장함

2) 주변 정보 확장 실험

◦ 1-2 에서 공정 Si와 Al_3Ni의 경계를 구분하려면 넓은 주변 정보가 필요하다고 보았으므로, 한 번에 보는 조각의 크기를 단계적으로 키움 (<그림 3-1>(b))

- 추론 조각을 512 → 768 → 1,024 로 키우자 mIoU가 80.05% → 80.22% → 80.25%로 올랐음
- 학습 조각을 768 로 키운 모델 3 개만으로 구성한 앙상블은 80.36%였고, Al_3Ni IoU가 75.9%에서 76.4%로 가장 크게 올라 가설과 같은 방향의 결과를 보임

◦ 마지막 향상폭(+0.14%p)은 시드 편차(약 0.14%p)와 비슷해 소폭 향상으로 해석함. 학습 960 · 추론 1,536 에서는 추가 개선이 없어 본 실험에서는 768~1,024 이후 포화 경향을 보임



<그림 3-1> 단계별 성능 향상과 조각 크기에 따른 성능

* (a) 회색은 딥러닝 이전 방식, 빨간색은 최종 모델 (b) 한 번에 보는 조각이 클수록 점수가 오름 (모두 2 배 확대 기준)

3) 앙상블

◦ 같은 구조에서 시드(42 · 7 · 123 · 2024), 학습 길이(100 · 150 에폭), 학습 조각(512 · 768)만

다르게 학습한 모델 7 개와 조직 크기 정규화 학습 모델 3 개, 총 10 개의 확률을 평균함

4) 비교 실험

◦ 주요 비교 실험은 <표 3-1>과 같으며, 각 실험은 같은 그룹의 기준(A 또는 B)과 비교함

- 시드 편차가 약 0.14%p이므로 +0.10%p를 후보 기준으로 두고, 상별 성능·오류 사례를 함께 확인해 최종 채택함
- 응고 순서를 반영한 계층 손실과 가는 구조를 보존하는 손실(Skeleton Recall) [5]도 설계·검증하였으나 기준보다 개선되지 않아 최종 모델에서 제외함

<표 3-1> 주요 비교 실험 결과

구분	실험 (2 배 확대, 검증 20 장, TTA 8 방향)	mIoU(%)
기준 A	U-Net + ResNet34, CE + Dice, 60 에폭	78.91
인코더	ResNeXt50 / MiT-B2(트랜스포머)	78.68 / 78.28
구조	UNet++ / scSE 주의 모듈	79.11 / 79.25
손실·전처리	경계 가중 손실 / 3 배 확대	78.86 / 78.38
기준 B	scSE + CE·Lovász, 100 에폭 / 150 에폭	79.76 / 79.74
사전학습	MicroNet 현미경 영상 가중치	79.72
손실	가는 구조 보존(Skeleton Recall) / 응고 순서 계층 손실	78.84 / 79.48
전처리	배율 통일(가로 2,560 픽셀)	79.03
최종	기준 B 시드 앙상블 4 개 → 추론 조각 1,024 → 학습 조각 768 모델 3 개 추가 → 작은 사진 2·3·4 배 평균 → 조직 크기 정규화 학습 3 개 추가	80.06 → 80.25 → 80.39 → 80.73 → 80.93

3-3. 성능

1) 검증 성능

◦ train 70 장으로만 학습한 최종 모델로 validation 20 장을 분할하고, 사진별 4 상 mIoU를 20 장 평균한 결과 80.93%임 (<표 3-2>)

- 모델 10 개의 단독 점수는 79.83~80.68%이며 확률 평균으로 0.25%p 더 높아졌고, 사진별 점수는 63.9%(A71)~89.7%(A44)임

◦ IoU 외에 정밀도(칠한 픽셀 중 정답 비율)와 재현율(정답 픽셀 중 찾아낸 비율)을 함께 계산하여 오차의 성격을 확인함 (<표 3-2>)

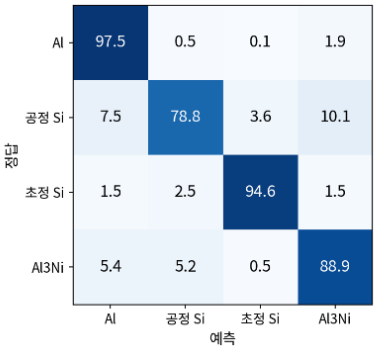
- 공정 Si의 정밀도(78.4%)와 재현율(78.8%)이 유사해 FP·FN 한쪽으로 크게 치우치지 않았고, 정성 분석에서는 오차가 주로 경계·미세 조각에서 확인됨

<표 3-2> 최종 모델의 검증 데이터 상별 성능 (검증 20 장, %)

지표	Al	공정 Si	초정 Si	Al_3Ni	평균
IoU	94.3	62.4	91.6	76.8	80.93 (mIoU)
정밀도	97.0	78.4	95.5	90.0	-
재현율	97.5	78.8	94.6	88.9	-
F1	97.2	78.6	95.1	89.5	-

* IoU는 사진별 20 장 평균, 정밀도·재현율·F1 은 전체 픽셀 기준임. 픽셀 정확도 93.9%는 다수 클래스 Al의 영향이 커 mIoU를 주 지표로 사용함

2) 오류 분석



<그림 3-2> 검증 데이터 혼동 행렬

◦ 오류는 공정 Si에 집중되며, 공정 Si 픽셀의 10.1%를 Al_3Ni로, 7.5%를 Al로, 3.6%를 초정 Si로 예측함 (<그림 3-2>)

- Al3Ni 혼동은 1-2 의 밝기 분포 중첩과 같은 방향이며, Al 혼동은 뒤의 정성 분석에서 얇은 경계 차이와 함께 확인됨
- 초정 Si 재현율은 94.6%로, 검증 데이터에서는 크고 각진 형태 정보가 구분에 기여한 것으로 보임
- Al_3Ni의 오류는 Al(5.4%)과 공정 Si(5.2%)로 고르게 나뉨

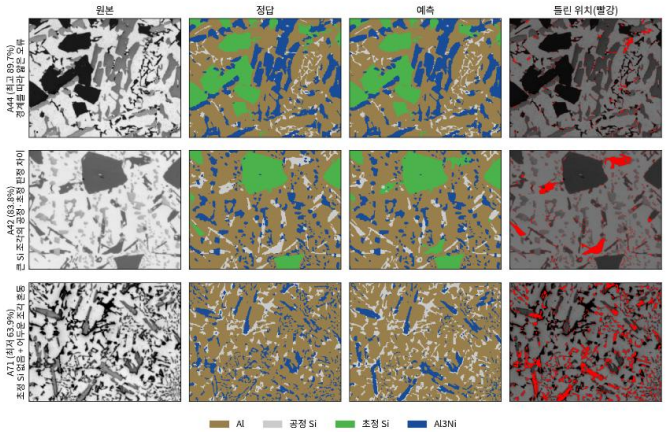
  * 행은 정답, 열은 예측이며 각 행의 합은 100%임

3) 정성 분석

◦ 경계・소형 조각은 1 픽셀 차이가 지표에 크게 반영될 수 있어, 검증 20 장의 원본・정답・예측・오류 위치를 비교해 네 유형으로 나눔 (<그림 3-3>)

- 경계 오차: 틀린 픽셀이 적은 A44(89.7%)・A170(88.4%)・A186(81.3%)은 틀린 픽셀이 3~4%이며, 대부분 조각 테두리를 따라 1 픽셀 폭으로 나타나고 조각 안쪽은 맞음
- 조각 단위 판정 차이: A42(83.8%)에서 일부 Si 조각을 정답은 공정 Si, AI는 초정 Si로 분류함. 두 상은 같은 Si이며 크기・형태로 구분되어 중간 크기 조각은 분류 기준의 경계 사례에 해당함
- 미세 조직 오차: A153(71.4%)・A67(75.9%)처럼 공정 조직이 잘게 얽힌 사진은 틀린 픽셀이 사진 전체에 흩어져 있으며, 조각이 수 픽셀에 불과해 경계 1 픽셀 차이가 조각 대부분의 오답으로 이어짐 (결과 폴더 비교 그림)
- 어두운 조각 혼동: 최저점 A71(63.9%)은 검게 찍힌 굵은 조각에서 공정 Si・Al_3Ni 판정이 엇갈리며(4)와 같은 원인), 초정 Si가 없어 사진에 있는 상끼리 평균하는 채점에서 어려운 두 상의 비중이 커진 측면도 있음

◦ 검증 20 장에서는 잔여 오류가 주로 1 픽셀 경계 차이와 분류 기준의 경계 조각에서 확인되며, 상 전체를 크게 잘못 분할한 사례는 드묾



<그림 3-3> 오류 유형별 정성 분석 사례 (최종 모델)

* 각 사진의 일부 영역을 원래 해상도로 확대함.

4) 남은 오차의 원인 분해

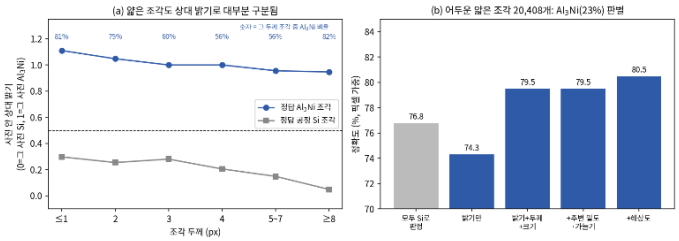
◦ 정답 마스크를 1 픽셀 옮긴 것을 예측으로 보고 채점하면 mIoU 78.62%(공정 Si 63.1%), 0.5 픽셀 옮기면 87.65%였음

- 공정 Si는 픽셀의 약 절반이 경계에 있어, 정답 경계의 1 픽셀 차이만으로도 점수가 크게 깎임
- 공정 Si IoU(62.4%)가 정답 1 픽셀 이동 시 IoU(63.1%)와 유사해, 성능이 1 픽셀 경계 변화에 매우 민감함을 확인함

◦ AI가 공정 Si와 Al_3Ni를 서로 바꿔 칠한 조각 5,879 개는 두께 1.8 픽셀・크기 12 픽셀로 맞은 조각(3.0 픽셀・29 픽셀)보다 얇고 작았으며, 약 3 분의 2 는 정답이 Al_3Ni인 조각을 Si로 칠한 경우였음

◦ 정답 90 장의 조각 99,037 개를 보면 얇은 조각도 사진 안 상대 밝기로 대부분 구분되나, 어둡게 찍힌 얇은 조각 20,408 개 중 23%는 정답이 Al_3Ni였음 (<그림 3-4>)

- 밝기・두께・크기・주변 밀도・해상도를 모두 써도 정확도는 80.5%로, 모두 Si 판정(76.8%)보다 3.7%p 높아 현재 특징만으로는 추가 구분 개선 폭이 제한적이었음



<그림 3-4> 얇은 조각의 상대 밝기와 어두운 얇은 조각의 판별 한계

* (a) 0 은 그 사진의 Si 밝기, 1 은 Al_3Ni 밝기이며, 위 숫자는 두께별 Al_3Ni 비율임 (b) 사진 단위 5 겹 교차검증, 픽셀 가중 정확도

◦ 이 오차를 줄이기 위한 추가 실험은 <표 3-3>과 같이 모두 채택 기준에 미달함

- Si・Al3Ni 영역 밝기 증강은 A71 을 61.0%에서 57.9%로 낮춰, 현재 학습 조건에서는 형태 단서 활용 개선으로 이어지지 않음
- 반면 예측 단계의 사진별 밝기 보정은 A71 을 8.8%p 높여, 해당 사진의 오류에 촬영 밝기 차이가 일부 기여했음을 확인함

<표 3-3> 채택하지 않은 추가 실험 (검증 20 장, 비교 기준 80.39%, *는 최종 80.93% 기준)

실험	방법	mIoU(%)
밝기 자기보정	1 차 예측으로 사진별 상 밝기를 맞춘 뒤 재예측	79.50
상별 밝기 증강	학습 때 Si·Al_3Ni 밝기만 따로 이동, 모델 3 개 추가	80.27
배율 하한·손실 *	정규화 학습 배율 하한 1.5 → 1.0 / 여기에 사진 단위 IoU 손실 추가, 각 모델 3 개	80.97 / 80.96

5) 제출 및 재현성

◦ test 10 장은 같은 모델로 분할하여 제출하였으며, 제출 코드(predict.py)를 zip만 풀어 다시 실행하면 검증 mIoU 80.93%와 제출 마스크(픽셀 일치율 100.000%)가 그대로 나오며, RTX 4070 기준 약 8 분 소요됨

◦ 실행 결과는 code.zip의 results 폴더에 자동 저장되어 코드를 돌리지 않고도 확인할 수 있음

- 모델별・사진별・상별 IoU, 정밀도・재현율, 혼동 행렬(metrics.json)과 검증 20 장의 원본・정답・예측・오류 비교 그림을 포함함

④ 재료공학적 활용: 탄성률 추정 및 역설계

1) 방법

◦ 분할 상 분율을 다상 Hashin–Shtrikman 경계식 [6]에 넣어 탄성률 하한·상한을 구하고, 중간값을 비교용 대표 추정값으로 사용함

- 상별 탄성 상수는 <표 4-1>의 문헌값을 사용하였으며, Al_3Ni는 실측값을 찾지 못해 제 1 원리 계산값을 사용함

<표 4-1> 상별 탄성 상수

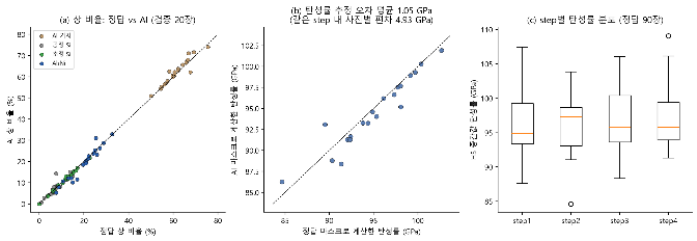
상	E (GPa)	ν	출처
Al 기지	70	0.33	일반 문헌값
Si (공정·초정)	160	0.22	[7] 다결정 Si 실측 155~164 GPa
Al_3Ni	143	0.29	[8] 제 1 원리 계산

2) AI 분할 기반 탄성률의 신뢰성

◦ 검증 20 장에서 정답 마스크와 AI 마스크로 각각 탄성률을 계산한 결과, 차이는 평균 1.05 GPa였음 (<그림 4-1>)

◦ 같은 step 내 사진별 HS 탄성률 추정값 변동은 4.93 GPa로, AI·정답 마스크 간 평균 차이(1.05 GPa)보다 큼

- 본 데이터에서는 분할 오차의 탄성률 계산 영향이 사진 간 변동보다 작았으며, 자동 분할은 여러 시야의 상 분율 계산 부담을 줄일 수 있음



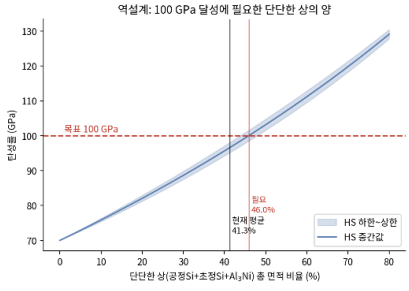
<그림 4-1> 정답 대비 AI의 상 분율·탄성률 비교

* (a) 점선에 가까울수록 정답과 같음 (b) 사진 1 장당 탄성률 비교 (c) 정답 90 장 기준 step별 탄성률 분포, AI 값은 작은 사진 배율 적용 전 모델 기준임

3) 100 GPa 역설계

◦ 현재 데이터의 평균 Si/Al_3Ni 구성비와 HS 중간값을 유지해 계산하면, 현재 평균 경질상 41.3%(약 96.6 GPa)에서 100 GPa에는 경질상 약 46%가 필요함 (<그림 4-2>)

◦ 탄성 상수의 문헌 범위(Si 155~164 GPa, Al_3Ni 140~143 GPa) 안에서 값을 바꾸어도 필요 분율은 45.3~46.8%로, 결론이 상수 선택에 크게 좌우되지 않음을 확인함



<그림 4-2> 경질상 분율에 따른 탄성률과 100 GPa 달성 조건

* 띠는 HS 하한~상한, 실선은 중간값이며, 검은 선은 현재 평균, 빨간 선은 100 GPa에 필요한 분율임

4) 활용 방안

◦ 새 시편은 상 분할 → 상 분율 → HS 기반 탄성률 추정값 계산으로 이어지며, 조건별 사진을 축적하면 조건 → 조직 → 물성 관계 분석 데이터로 확장할 수 있음

⑤ 한계 및 시편 준비 지침

◦ 공정 Si IoU(62.4%)가 정답 1 픽셀 이동 시 IoU(63.1%)와 유사해, 추가 개선에는 모델뿐 아니라 영상 해상도와 경계 라벨링 정밀도도 함께 고려해야 함

◦ 확인한 오차 원인을 바탕으로 자동 분석의 정확도를 높이는 준비 지침을 <표 5-1>과 같이 제안하며, 시편당 여러 시야 촬영(4-2)도 함께 권장함

<표 5-1> 분석 정확도를 높이는 시편·촬영 준비 지침

항목	본 분석의 근거	지침
촬영 해상도	675×480 사진은 공정 Si 2.0 픽셀, 작은 사진 점수 낮음	공정 Si가 4 픽셀 이상 되도록 배율·해상도 통일
에칭·조명	Si·Al_3Ni가 어둡게 찍힌 A71 에서 상 혼동 증가	에칭 시간·조명 조건 고정, 기준 시편 함께 촬영
얇은 상 판정	어두운 얇은 조각의 23%가 Al_3Ni, 사진으로 구분 한계	일부 시야를 SEM-BSE·EDS로 확인해 정답 보정

추가 연구 방향

◦ 외부 검증: 다른 현미경・배율로 찍은 시편 사진에 자동 배율을 적용하여, 촬영 배율 정보 없이도 성능이 유지되는지 확인할 필요가 있음

◦ 정답 보정: 공정 Si・Al_3Ni 판정이 엇갈린 얇은 조각을 SEM-BSE・EDS로 확인해 정답을 보정하면, 경계 불확실성과 실제 모델 오차를 분리하여 평가할 수 있음

◦ 물성 연결 고도화: 분할 마스크를 유한요소 해석에 넣어 상의 형상・배열 효과를 반영하고, 나노압입으로 Al_3Ni 탄성 상수를 실측하면 탄성률 추정의 신뢰도를 높일 수 있음

◦ 공정 설계 연계: step별 사진과 탄성률을 함께 축적하면 공정 조건 → 상 분율 → 탄성률 관계를 학습하여 100 GPa 달성 조건을 역으로 제안하는 데 활용할 수 있음

참고문헌

[1] O. Ronneberger et al., U-Net, MICCAI (2015).

[2] J. Stuckner et al., Microstructure segmentation with deep learning encoders pre-trained on a large microscopy dataset, npj Comput. Mater. 8 (2022) 200.

[3] A.G. Roy et al., Concurrent spatial and channel squeeze & excitation in fully convolutional networks, MICCAI (2018).

[4] M. Berman et al., The Lovász-Softmax loss, CVPR (2018).

[5] Y. Kirchhoff et al., Skeleton Recall Loss, ECCV (2024).

[6] Z. Hashin, S. Shtrikman, A variational approach to the theory of the elastic behaviour of multiphase materials, J. Mech. Phys. Solids 11 (1963) 127–140.

[7] S.W. Cho, I. Chasiotis, Elastic properties and representative volume element of polycrystalline silicon for MEMS, Exp. Mech. 47 (2007) 37–49. [8] D. Shi et al., First-principles studies of Al–Ni intermetallic compounds, J. Solid State Chem. 182 (2009) 2664–2669.